



**T.C.
NECMETTİN ERBAKAN
ÜNİVERSİTESİ
SEYDİŞEHİR AHMET CENGİZ
MÜHENDİSLİK FAKÜTESİ**



BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

Yapay Zeka ile Sosyal Medyadaki Nefret İçerikli Yorumların Tespiti

20370031025 Hilal Akçakaya

**Danışman:
Dr. Öğr. Üyesi Halime Ergün**

**BİLGİSAYAR MÜHENDİSLİĞİNDE
TASARIM I-II TEZİ**

**Ekim-2023
SEYDİŞEHİR
Her Hakkı Saklıdır**

LİSANS BİTİRME ÖDEVİ SONUÇ FORMU

Hilal Akçakaya tarafından Halime Ergün danışmanlığında hazırlanan “Makine Öğrenmesi ile Sosyal Medyadaki Nefret İçerikli Yorumların Tespiti” başlıklı lisans bitirme ödevi tarafımızdan incelenmiş, kapsamı ve niteliği açısından, ... / ... / 20... tarihinde bir Lisans Bitirme Ödevi olarak kabul edilmiştir / edilmemiştir.

Dr. Öğr. Üyesi Halime Ergün

Danışman

Unvan Ad SOYAD

Jüri Üyesi

Unvan Ad SOYAD

Jüri Üyesi

Unvan Ad SOYAD

Bölüm Başkanı

TEZ BİLDİRİMİ

Bu tezdeki bütün bilgilerin etik davranış ve akademik kurallar çerçevesinde elde edildiğini ve tez yazım kurallarına uygun olarak hazırlanan bu çalışmada bana ait olmayan her türlü ifade ve bilginin kaynağına eksiksiz atıf yapıldığını bildiririm.

DECLARATION PAGE

I hereby declare that all information in this document has been obtained and presented in accordance with academic rules and ethical conduct. I also declare that, as required by these rules and conduct, I have fully cited and referenced all material and results that are not original to this work.

Seydişehir, / / 20...
İmza

ÖZET

Yapay Zeka ile Sosyal Medyadaki Nefret İçerikli Yorumların Tespiti

Nefret içerikli yorumlar, son yıllarda internet ortamında ciddi bir sorun haline gelmiştir. Bu tür yorumlar, bireylere ve toplumlara karşı psikolojik ve sosyal zararlar verir. Bu nedenle, nefret içerikli yorumları tespit etmek ve engellemek büyük bir önem taşımaktadır. Bu tez çalışması nefret içerikli yorumların tespiti için LightGBM algoritması ve MultiOutputClassifier modelini kullanılmıştır. LightGBM algoritması, hızlı performansı ve doğruluk oranındaki üstünlüğü ile bilinen bir makine öğrenme algoritmasıdır. MultiOutputClassifier modeli ise çoklu çıktı (multi-output) sınıflandırma problemleri için etkili bir araçtır. Bu çalışmanın sonuçları nefret içeren yorumların tespitinde LightGBM algoritmasının ve MultiOutputClassifier modelinin başarılı olduğunu göstermiştir. Modelin eğitimi yapılmış veri kümesi üzerinde gerçekleştirilmiş ve elde edilen sonuçlar oldukça olumlu olmuştur. Bu modelin sosyal medya platformları gibi çevrimiçi platformlarda kullanılmasıyla, nefret içeren yorumların yaygınlığı azaltılabilir ve internet ortamının daha saygılı hale getirilmesine katkı sağlanması amaçlanmıştır. Bu tez çalışması, internet ortamındaki negatif davranışları azaltmak amacıyla yapılacak mücadelede önemli bir adım olarak değerlendirilebilir. Sonuç olarak, bu tez çalışması LightGBM algoritmasının ve MultiOutputClassifier modelinin nefret içeren yorumları tespit etmek için etkili araçlar olduğunu göstermiştir. Bu çalışma, dijital dünyada daha güvenli bir ortam oluşturmak için yapılacak çabalara destek sağlamaktadır. Nefret içeren davranışları azaltma konusunda ilave araştırmaların yapılması önemlidir ve bu konuda daha fazla farkındalık oluşturulmalıdır.

Anahtar Kelimeler: Instagram, LightGBM, MultiOutputClassifier, Makine Öğrenmesi, Nefret Söylemi, Sosyal Medya, Tiktok

ABSTRACT

Detection of Hateful Comments on Social Media with Artificial Intelligence

Hateful comments have become a serious problem on the internet in recent years. Such comments cause psychological and social harm to individuals and societies. Therefore, detecting and blocking hateful comments will be of great importance. In this thesis study, LightGBM scans and MultiOutputClassifier persona were used to identify hateful comments. LightGBM software is a machine learning solution known for its fast performance and accuracy rate advantage. The MultiOutputClassifier model is an effective tool for multi-output solutions. The results in this book show that the LightGBM versions and the MultiOutputClassifier model are successful in detecting hateful comments. Data setup was performed in model training and the results were very positive. By using this model on online platforms such as social media platforms, the prevalence of hateful comments can be reduced and contribute to making the internet environment healthier. This thesis can be considered as an important step in the fight to reduce negativity on the internet. As a result, this thesis study shows that the LightGBM update and the MultiOutputClassifier model are effective tools for detecting hateful changes. This study supports efforts to create a safer environment in the digital world. Additional research on hateful expansion is important, and more on this topic should be established on a permanent basis. Hateful comments have become a common problem online. These comments cause psychological and social harm to individuals and groups. Therefore, detecting and preventing hateful developments is an important task. In this thesis, LightGBM openings and the MultiOutputClassifier model were demonstrated as an effective tool for detecting hateful views. The model can be used to make social media platforms more secure. By using this model, the prevalence of hateful comments can be reduced and increased on the internet.

Keywords: Instagram, LightGBM, MultiOutputClassifier, Machine Learning, Hate Speech, Social Media, TikTok

ÖNSÖZ

Önsöz metnini yazım kılavuzuna uygun olarak yazmaya buradan başlayınız. Bu kısımda proje metni içinde yazımı durumunda anlatım bütünlüğünü bozacağı varsayılan, yalnız projeyi hazırlayan tarafından sunulmak istenen çalışma ile ilgili ek bilgiler ile çalışmayı etkileyen faktörlerden bahsedilir. Klasik önsöz düzeninde ve en çok bir sayfa olarak yazılmalıdır.

Önsözün son kısmında proje çalışmasında doğrudan katkısı bulunan kişilerle, doğrudan ilgili olmadığı halde olağan görevi dışında katkıda bulunmuş kişi ve/veya kuruluşlara teşekkür edilebilir. Teşekkür edilen kişilerin unvanı (varsa), adı soyadı, görevli olduğu kuruluş ve çalışmaya olan katkısı kısa ve öz bir şekilde belirtilebilir. Proje çalışması herhangi bir kurumdan destek alarak gerçekleşmişse, projenin ve projeye destek sağlayan ilgili kuruluşun adı da bu bölümde belirtilmelidir.

20370031025- Hilal Akçakaya
SEYDİŞEHİR - 2023

İÇİNDEKİLER

ÖZET	iv
ABSTRACT	v
ÖNSÖZ	vi
İÇİNDEKİLER	vii
ŞEKİLLER DİZİNİ	viii
ÇİZELGELER DİZİNİ.....	ix
SİMGELER VE KISALTMALAR.....	x
1. GİRİŞ	1
1.1. Problem	1
1.2 Amaç	1
2.KAYNAK ARAŞTIRMASI	3
2.1.Nefret İçerikli Söylemler ile Mücadele	3
2.2. Nefret İçerikli Söylemlerin Tespit Edilmesi	3
3.MATERYAL VE YÖNTEM.....	7
3.1 Yapay Zekâ	7
3.2 Kullanılan Kütüphaneler ve Fonksiyonlar	7
4. ARAŞTIRMA SONUÇLARI VE TARTIŞMA	11
4.1 Modelin Eğitilmesi	11
4.2 Sosyal Medyadan Yorum Çekilmesi ve Arayüz Tasarımı.....	11
5. SONUÇLAR VE ÖNERİLER	19
5.1 Sonuçlar	19
5.2 Öneriler	19
6. KAYNAKLAR.....	20
ÖZGEÇMİŞ.....	23

ŞEKİLLER DİZİNİ

- Şekil 1. Kaggle'dan alınan veri seti
- Şekil 2. Streamlit ile oluşturulan giriş sayfası
- Şekil 3. Streamlit ile oluşturulan kullanıcı ana sayfası
- Şekil 4. Nefret içerik türleri ve sayısı
- Şekil 5. Olumsuz yorum yapan kullanıcılar
- Şekil 6. Tarihe göre olumsuz yorum sayısı
- Şekil 7. Kullanıcı yardım paneli
- Şekil 8. Yardım paneli
- Şekil 9. İletişim paneli

ÇİZELGELER DİZİNİ

Tablo 1. Nefret içerik tespiti	Error! Bookmark not defined.
Tablo 2. Nefret içerikli yorumların türünün tespit edilmesi	14

SİMGELER VE KISALTMALAR

Kısaltmalar

CNN	: Evrişimsel Sinir Ağları (Convolutional Neural Network)
YZ:	: Yapay Zeka (Artificial Intelligence)
ML	: Makine Öğrenmesi (Machine Learning)
NLP	: Doğal Dil İşleme (Natural Language Processing)
NB	: Naif Bayes (Naive Bayes)
SVM	: Destek Vektör Makineleri (Support Vector Machine)
LSTM	: Uzun Kısa Süreli Bellek (Long Short-Term Memory)
BİLSTM	: Çift Yönlü Uzun Kısa Süreli Hafıza (Bidirectional Long Short-Term Memory)
XGB	: Aşırı Gradyan Artırma (Extreme Gradient Boosting)
TF-IDF	: Terim Frekansı-Ters Belge Frekansı (Term Frequency-Inverse Document Frequency)
API	: Uygulama Programlama Arabirimi (Application Programming Interface)
IDE	: Entegre Geliştirme Ortamı (Integrated Development Environment)

1. GİRİŞ

Günümüz teknoloji çağında sosyal medya kullanımı her geçen gün artmaktadır. Sosyal medya kullanımı arttıkça insanlar arası iletişim de doğru oranda artmaktadır. Artan iletişimin olumsuz yanlarından biri de nefret içerikli yorumlardır. Nefret içerikli yorumlar dil, din, ırk, cinsiyet, cinsel yönelime yönelik sözlü şiddettir. Sanal zorbalığa maruz kalan kişilerde ruh sağlığı açısından birçok olumsuz sonuçları olabilecek nefret içerikli yorumların sosyal medyada tespit edilmesi de çok önemlidir.

Bu araştırmada sosyal medyadan alınmış yorumları nefret içerikli olup olmadığını tespit edebilmek için Yapay Sinir Ağları kullanılır. Bu çalışmanın amacı farklı algoritmalar kullanarak en iyi sonucu veren yapay sinir ağının bulunmasıdır. Python kütüphaneleri kullanılarak alınan sonuçlar görselleştirerek grafik üzerinde karşılaştırılır. Bu projenin bitiminde ulaşmak istediğimiz hedef nefret içerikli yorumların tespit edilmesi ve sınıflandırılması alanında önemli bir adım atmaktır.

1.1. Problem

Günümüzde sosyal medya kullanımının artışının yanında bazı sorunlar da yanında artmıştır. Bunlardan biri de nefret içerikli yorumlardır. Nefret içerikli yorumların yaygınlaşmasının ardından nefret ifadelerinin insan üzerinde etkisi gözlemlendiğinde bu yorumların hedefinde olan kişilerde düşük benlik saygısı, kaygı, depresyon gibi psikolojik rahatsızlıklara yol açabilmektedir (Aksakallı G.,2023).

1.2 Amaç

Bu tez çalışması ile:

- Farklı sosyal medya ortamlarından yorumların çekilmesi,
- Sosyal medyadaki yorumların analiz edilerek nefret içerikli yorumların tespit edilmesi,
- Bu yorumların silinmesi için çalışmalar yapılması,
- Nefret içerikli yorumların kategorize edilerek raporlanması,
- Nefret içerikli yorumların insan üzerindeki fiziksel ve duygusal etkisini azaltmak,
- Sosyal medyada nefret içerikli yorumların azalması,
- Derin öğrenme alanında çalışma yaparak literatüre katkıda bulunulmak istenmiştir.

1.3 Varsayımlar

Kullanılan veri setinde imla yanlışlarının olmadığı ve veri işlenirken cümledeki anlam bütünlüğünün bozulmadığı kabul edilmiştir.

1.4 Sınırlılıklar

Makine öğrenmesinin gelişimiyle birlikte verinin de önemi artmaktadır. Modelde kullanılan veri seti başarıyı doğru oranda etkilemektedir. Araştırmada kullanılan veri setindeki örnek yorumların uzunluğu, örnek cümle sayısı alınan sonuçla doğru orantılıdır.

2.KAYNAK ARAŞTIRMASI

Bu bölümde sosyal medyadaki nefret içerikli ifadelerin tespit edilmesi üzerine yapılmış çalışmalara yer verilmektedir.

2.1.Nefret İçerikli Söylemler ile Mücadele

Nefret söylemini kabul eden ilk hükümetler arası kuruluş olan Avrupa Konseyi 1997 yılında kurulmuştur (Çelik D.,2023).

Türk Ceza Kanunu'nda 2014 yılında yapılan değişiklik ile ırk, devlet, milliyet, renk, cinsiyet, engellilik, siyasi düşünce, felsefi inanç, din veya mezhep farklılığından kaynaklanan nefrete dayalı ayrımcılığı suç saymıştır. Bir yıldan üç yıla kadar hapis cezası ile cezalandırılır (Doğan B.,2023)

Birleşmiş Milletler insan haklarını korumak için nefret içerikli yorumlarla mücadele etme konusunda yaptığı birçok çalışma vardır.18 Haziran 2019'da nefret, ırkçılık, ayrımcılık konularını merkez alan Birleşmiş Milletler Nefret Söylemi Stratejisini ve Eylem Planını açıkladı (Birleşmiş Milletler,2022).

2.2. Nefret İçerikli Söylemlerin Tespit Edilmesi

Greevy E. ve arkadaşı (2004) çalışmasında ırkçı metinler tespit edilmeye çalışılmıştır. Diğer zorbalık türlerine göre ırkçılığı tespit etmek zordur. Metindeki kelimeler ırkçılığı belirlemekte yetersizdir. Destek Vektör Makineleri kullanılarak ırkçı metinleri sınıflandırmak amaçlanmıştır. Oluşturulan model sayesinde web sayfalarının ırkçı olup olmadıklarına göre kategorize eder.

Kwok ve arkadaşı (2013) çevrimiçi içeriklerde otomatik nefret söylemi tespiti çalışması ile Twitter'da ırkçılık hakkında nefret söylemi içeren ifadeleri %76 oranında doğru tespit edebilmiştir.

Davidson T. ve arkadaşları (2013) araştırmasında nefret söylemi içeren tweet'leri toplamak için kitle kaynaklı bir nefret söylemi kullanılmıştır. Oluşturulan veri seti üç kategoriye ayrılmıştır. Nefret söylemi içerenler, saldırgan dil içerenler ve ikisini de içermeyenler. Bu kategoriler ayırt etmek için çok sınıflı sınıflandırıcı kullanılır. Araştırmanın sonucunda ırkçı ve homofobik tweetleri nefret söylemi olarak sınıflandırma olasılığı daha yüksekken, cinsiyetçi tweetleri genellikle saldırgan olarak sınıflandırmıştır.

Burnap P. ve arkadaşı (2014), 2013 yılında Drummer Lee Rigby in Woolwich öldürülmesi sosyal medyada tepkiye yol açmasının ardından bu çalışmaya başlanmıştır. Veri seti olarak Lee Rigby'in cinayetinin ardından Twitter'dan gelen tepkiler kullanıldı. Oluşturulan denetimli makine öğrenmesi modeli nefret içeren örnek bir tweet üzerinde test edilmiştir. %95 oranında bir F1 skoru elde etmişlerdir.

Padmaja PS. ve arkadaşı (2014) araştırmasında NDTV ve The Hindu olmak üzere iki farklı kaynaktan alınan haberleri kullanmaktadır. Araştırmanın amacı iki makine öğrenimi tabanlı ve bir sözcük tabanlı model kullanarak haberleri iyi ve kötü duygular olarak ayrıştırılması ve analiz edilmesidir. BJP ve UPA adlı iki siyasi partinin haberleri incelendiğinde en iyi F1 skoru 0,688 ve 0,657 ile SVM modeliyle ulaşılmıştır.

Raisi E. ve arkadaşı (2017) çalışmasında taciz temelli zorbalıkları tespit etmek için makine öğrenme yöntemi öneriliyor. Algoritma hangi kullanıcının zorba, hangi kullanıcının mağdur olduğu sonucunu çıkarır. Zayıf denetimli makine öğrenmesini kullanarak eğitilen modeli üç sosyal medya veri seti üzerinde test etmişlerdir.

Tomkins S. ve arkadaşı (2018) araştırmasında siber zorbalık içeren mesajları tespit eden sosyo-dilsel bir model öneriyorlar. Zorbalığa yönelik mesajlar subjektif olduğu için bunu model gürültülü ve tutarsız olarak algılıyor. Bu çalışmada tutarsız etiketleri atmak yerine modelin öğrenmesinde bu veriler de kullanılıyor. Bu sayede diğer çalışmalara göre %18'lik iyileşme gözlenmiştir.

Kolhatkar V. ve arkadaşları (2019) 5 yıllık dönemde makaleler, Kanada gazetesi The Globe gibi kaynaklardan alınan verilerin analiz edilmesini hedefleyen projede veri setindeki tartışmaların türleri, yorumcuların hoş veya kaba yanıtlarını içerir. Kullanılan veri setinin büyüklüğü 303.665'dir. Rastgele 100 veriden oluşan örneklem üzerinde %87,88 doğruluğa ulaşmışlardır.

Al Z. ve arkadaşı (2019) son on yılda sosyal medya kullanımının artmasından dolayı makine öğrenmesi ve doğal dil işleme yöntemlerini karıştıran bir model eğitmişlerdir. İlk olarak nefret yorumlarının toplanması ardından cümleleri tokenlarına bölme, özel karakterleri çıkarma ve kelimelerdeki çekimleri yok etme aşamaları izlemektedir. Temizlenmiş veri seti KNLPEdNN modeli kullanarak eğitilir. %98,71 doğruluk sonucuna ulaşılır.

Florio K. ve arkadaşları (2019) çalışması İtalya'daki göçmenlerin varlığına yönelik siber nefret söylemi üzerinedir. İtalyan Twittersphere'den ve İtalya'daki resmi istatistik verilerinin ana tedarikçisinden (ISTAT) toplanan veriler denetimli sınıflandırma

modeliyle eğitilmiştir. Sonuç olarak ekonomik ve kültürel faktörler ile siber nefret ifadesi arasında bir etkileşim olduğu düşünülmüştür.

Bist A. ve arkadaşları (2020) Twitter verileri üzerine yaptıkları çalışmada LSTM tabanlı sınıflandırmayı kullandılar. En iyi performansı erken durdurma ile LSTM kullanarak %86 doğruluk sonucu elde etmişlerdir.

Islam MM. ve arkadaşları (2020) araştırmanın amacı, doğal dil işleme ve makine öğrenimini birleştirerek sosyal medyadaki taciz ve zorbalık içeren mesajları tespit etmek için model geliştirmektir. Sözcük Torbası (BoW) ve terim frekansı ters metin frekansı (TFIDF) olmak üzere iki farklı özellik, dört farklı makine öğrenme algoritması kullanılır.

Aljarah I. ve arkadaşı (2020) Arap bölgesindeki Arap sosyal medya kullanıcılarının sayısı hızla artmaktadır. Ve buna bağlı olarak da nefret söylemi de artmaktadır. Bu sebeple nefret barındırmayan çevrimiçi ortamların arzulanması nedeniyle ortaya çıkmıştır. Twitter platformu üzerinden Arapça nefret söylemlerini NLP teknikleri ve makine öğrenmesi kullanılarak tespit edilmesi hedeflenmiştir. İşlenen veri seti, SVM, NB, DT ve RF kullanılarak eğitilir. En iyi sonuca RF sınıflandırıcısından ulaşılmıştır.

Herodotou H. ve arkadaşları (2021) bu çalışmada akıllı ML kullanarak Twitter'da saldırgan içerikleri tespit etmeyi konu alıyor. %82,93 oranında doğruluk performansına ulaşır. Dakikalar içerisinde milyonlarca tweet'i işleyerek kolayca sonuca varacak şekilde literatüre çalışma eklemişlerdir.

Ganesh R. ve arkadaşı (2021) çalışmada CNN ve LSTM gibi derin öğrenme modellerini kullanarak daha iyi sonuçlar elde edilebileceği düşünülmüştür. CNN modeli giriş ve çıkış katmanı da dahil edilerek beş katmandan oluşur. Facebook'tan ve diğer sosyal medyalardan alınan yorumlar modeli eğitmek için kullanılır. Facebook'tan alınan veriler F1 puan ağırlığı 0,702 iken diğer sosyal medyaları için bu skor 0,603'tür.

Perifanos K. ve arkadaşı (2021) çalışmasında nefret içerikli yorumları bilgisayarlı görme ve doğal dil işleme modellerini birleştirerek tespit etmektedir. Yapılan araştırma Twitter'daki mülteci ve göçmenlere yönelik Yunanca nefret içerikleri yorumları kapsamaktadır. Nefret söylemi barındıran Twitter profili ve yorumu web tarayıcısında göstermeyi amaçlamışlardır. Oluşturulan model %97 doğruluk oranına ulaşmıştır.

Özbay E. (2022) çalışmasında Twitter veri seti olan Cyber -Trolls kullanılarak saldırganlık tespit edilmesi hedeflenmiştir. 20001 adet tweet içeren veri Naive Bayes, Destek Vektör Makinesi, K-En Yakın Komşu sınıflandırmaları ile eğitilmiştir. Kullanılan farklı sınıflandırma ve transformatör kombine edilerek en iyi sonuç LMTweets+CNN ile elde edilmiştir. %96 doğruluk, %91 kesinlik sonuçları ortaya çıkmıştır.

K. Yousaf ve arkadaşı (2022) araştırmasında genç izleyicilerin çoğunluk oluşturduğu milyonlarca izleyicinin kullandığı YouTube üzerine durmuştur. Bu yüzden otomatik filtre mekanizması tavsiye edilmektedir. ImageNet önceden eğitilmiş evrişimli sinir ağı modeli kullanılır. 111.156 çizgi film klibinden oluşan, manuel açıklamalı bir veri kümesiyle eğitilmektedir. Sonuçlar EfficentNet-BİLSTM doğruluk oranı %95,66'dır. BİLSTM'nin mimarisinin video tanımlayıcılarının bağlamsal bilgilerini daha iyi yakaladığından dolayı daha iyi sonuç elde edilmiştir.

Priya ve arkadaşı (2023) etiketlenmiş veri kümesinde üzerinde eğittiği model ile siyasi nefret söyleminin belirlenmesi üzerine çalışmıştır. Siyasi söylem içeren tweetler RF, DC, Naive Bayes ve XGB gibi tekniklerle eğitilir. TF-IDF, sayım vektörizasyonu ve XG Boost kombinasyonu en doğru sonucu vermiştir.

Mahajan E. ve arkadaşları (2024) derin öğrenme tabanlı, çok dilli nefret söylemi ve siber zorba tespit modelinin birleşiminden oluşan yeni bir model önerdiler.

3.MATERYAL VE YÖNTEM

Bu bölümde, sosyal medyadaki nefret içerikli yorumların tespit edilmesi konusunu araştırmak için kullanılan materyal ve yöntemle araştırmada kullanılan materyal ve yöntemler açıklanmıştır.

3.1 Yapay Zekâ

Yapay Zeka (YZ), insan zekasını taklit eden ve problem çözme, öğrenme ve karar verme gibi görevleri yerine getiren bilgisayar sistemlerini ifade eder. Bu kavram ilk olarak 1950 yılında Alan Turing'in "Bilgisayar Makineleri ve Zeka" adlı makalesiyle ortaya çıkmıştır. Bu makaleden, bir bilgisayarın bir insan gibi düşünüp düşünemeyeceğini belirlemeyi amaçlayan "Turing Test" ortaya çıkar. Turing'in döneminde sorun, bir makinenin kararlarını saklama veya hatırlama yeteneğiydi. Hesaplama yapılabilirdi ancak bir bilgisayarın insan gibi düşünmesini sağlamak için gerekli olan bilginin saklanması için gerekli olan altyapı yetersizdi. (Yapay Zekâ,2024) Makina Öğrenmesi ve Derin Öğrenme yapay zekânın alt dalıdır. Makina Öğrenmesi, algoritmalar aracılığıyla deneyimlerden öğrenen ve zamanla performansını iyileştiren bir YZ alt dalıdır. Makine öğrenmesi modelleri, verilerden örüntüleri ve ilişkileri çıkararak tahminler ve çıkarımlarda bulunur. Makine Öğrenmesi iki çeşittir. Bunlar denetimli öğrenme ve denetimsiz öğrenmedir. Denetimli Öğrenme, Bu türde, modele önceden etiketlenmiş veriler sunulur. Model, bu verilerden yola çıkarak yeni veriler için doğru etiketleri tahmin etmeye çalışır. Denetimsiz Öğrenme, etiketlenmemiş veriler üzerinde çalışan bir makine öğrenmesi türüdür. Model, verilerdeki örüntüleri ve ilişkileri kendi kendine keşfeder. Derin Öğrenme, insan beyninin sinir ağlarından ilham alan bir makine öğrenmesi türüdür. Yapay sinir ağları, verilerden karmaşık ilişkileri ve örüntüleri öğrenmek için kullanılır. Derin öğrenme, görüntü işleme, doğal dil işleme ve ses tanıma gibi alanlarda kullanılır. Derin öğrenme makine öğrenmesine kıyasla daha büyük veriler üzerinde çalışabilirken makina öğrenmesi bu konuda sınırlıdır. Derin öğrenme daha karmaşık ilişkileri ve örüntüleri öğrenebilir ve aynı zamanda daha yüksek doğruluk oranlarına ulaşabilir.

3.2 Kullanılan Kütüphaneler ve Fonksiyonlar

Veri bir veya birden fazla bilgiden oluşmuş kümedir. Veri analizi ve veri görselleştirme, veri biliminin temel taşıdır. Büyük veri kümelerinden anlamlı bilgiler

çıkarmak ve bu bilgileri kullanarak daha iyi kararlar vermek, veri biliminin amaçlarından biridir. Bu alanda birçok Python kütüphanesi vardır. Pandas bu kütüphanelerden biridir. Bu kütüphane kullanılarak veri analiz edilir ve temizlenir. Verileri düzenlemek, analiz etmek, filtrelemek, gruplamak, sıralamak ve çizmek gibi birçok işlem için kullanılabilir. Verileri DataFrame ve Series gibi güçlü veri yapıları ile organize eder. Pandas, verileri hızlı bir şekilde yüklemek, düzenlemek ve veri madenciliği ve makine öğrenmesi gibi analitik işlemler için kullanılabilir. CSV, Excel, JSON gibi farklı veri formatlarını okuyabilir ve yazabilir. Ayrıca veri temizleme sayesinde modeli anlayarak daha iyi doğruluk sonucu almamıza yardımcı olur. (Pandas,2023) Numpy, Python'da bilimsel hesaplama için temel kütüphanedir. Diziler, matrisler ve diğer çok boyutlu veri yapıları üzerinde işlemler gerçekleştirmeye yardımcı olur. Matematiksel fonksiyonlar, trigonometrik fonksiyonlar, istatistiksel fonksiyonlar gibi birçok fonksiyon sunar. Pandas ile analiz edilen veriyi görselleştirilmek için Matplotlib kütüphanesi kullanılır. Matplotlib, Python'da veri görselleştirme için en popüler kütüphanedir. Çizgi grafikleri, histogramlar, pasta grafikler, dağılım grafikleri gibi birçok grafik türü oluşturabilir. 2D ve 3D grafikler oluşturabilir. Veri görselleştirme daha iyi analiz edilerek verilerin hızlı bir şekilde yorumlanmasını sağlar. Veriler yanlış örnekler bulunduruyorsa görselleştirme işleminde tespit edilebilir. LGBMClassifier, hızlı ve verimli bir Gradient Boosting çerçevesinin bir parçasıdır. Gradient Boosting algoritması, Decision Tree'leri ardışık olarak eğiterek güçlü bir model oluşturur. LGBMClassifier bu algoritmayı kullanarak sınıflandırma problemleri için etkili bir çözüm sunar. LightGBM, diğer Gradient Boosting yöntemlerine kıyasla daha hızlı çalışan ve daha az bellek tüketen bir algoritmadır. LightGBM'in önemli avantajlarından biri, kategorik özellikleri doğrudan işleyebilme yeteneğidir. Bu da ön işleme aşamasında zaman kazandırır. LGBMClassifier'ın bazı önemli parametreleri vardır. Parametrelerden biri olan num_leaves parametresi, Decision Tree'deki yaprak sayısını belirtir ve modelin karmaşıklığını kontrol eder. learning_rate parametresi ise her iterasyonda modelin güncellenmesi için kullanılan ağırlık oranını belirler. n_estimators parametresi ise toplamda kaç tane Decision Tree oluşturulacağını belirtir. Bu parametreleri ayarlayarak LGBMClassifier modelinin performansını optimize edilebilir. MultiOutputClassifier, Scikit-learn kütüphanesinin bir parçası olan ve çoklu çıkışlı sınıflandırma problemleri için kullanılan bir sınıflandırıcıdır. Çoklu çıkışlı sınıflandırma problemlerinde, birden fazla hedef değişkeni (etiket) bulunur ve her biri kendi bağımsız değişkenlerine (özelliklere) sahiptir. MultiOutputClassifier, her bir hedef için ayrı bir sınıflandırıcıyı eğiterek çalışır.

Bu sayede sınıflandırıcılar arasında herhangi bir bağlantı varsayılmamış olur. TfidfVectorizer, metin verilerini sayısal vektörlere dönüştürmek için kullanılır. TfidfVectorizer, iki önemli kavramı kullanarak metin verilerini dönüştürür. Bunlardan biri TF, terim frekansını ifade eder ve bir belgedeki belirli bir terimin ne sıklıkta geçtiğini gösterir. Bir terimin TF değeri, o terimin belgedeki toplam kelime sayısına bölünerek hesaplanır. IDF ise ters belge frekansını ifade eder ve bir terimin ne kadar yaygın olduğunu ölçer. Bir terimin IDF değeri, tüm belgelerin sayısının o terimi içeren belgelerin sayısına oranı olarak hesaplanır. Daha nadir olan terimlerin daha yüksek IDF değerleri vardır. TfidfVectorizer, her bir kelimenin TF-IDF vektörünü hesaplamak için bu iki istatistikten yararlanır. Her kelimeyi bir feature (özellik) olarak kabul ederek metni temsil etmek için bu vektörleri kullanır. TfidfVectorizer, genellikle metinsel verilerle çalışan makine öğrenimi modellerinde ön işleme aşamasında kullanılır. Metinsel verileri sayısal formata dönüştürerek model eğitime uygun hale getirmek için etkili bir araçtır. Pickle, Python'da nesneleri seri hale getirerek kaydetmeyi ve daha sonra tekrar yüklemeyi sağlayan bir kütüphanedir. Bu sayede verileri diskte saklayabilir ve daha sonra kullanabilir. `pickle.dump()` fonksiyonu bir nesneyi seri hale getirip belirtilen dosyaya yazmak için kullanılır. İlk parametre olarak seri haline getirmek istediğiniz nesneye ve ikinci parametre olarak da bir dosya nesnesine ihtiyaç duyar. `pickle.load()` fonksiyonu, Pickle ile kaydedilmiş bir dosyayı okumak ve içeriğini geri yüklemek için kullanılır. Pickle kütüphanesi genellikle model eğitimi sırasında oluşan modellerin veya büyük boyutlu veri setlerinin depolanması gibi durumlarda yaygın olarak kullanılır. `Urllib.parse`, bu modül, URL'leri ayrıştırma, birleştirme ve kodlama işlemlerini gerçekleştirmenize olanak sağlar. `urlparse()` bir URL'yi parçalarına ayırarak ayrıştırma işlemi yapar. `Googleapiclient.discovery`, Google API'lerini Python ile kullanmak için gerekli olan bir modüldür. Bu modül, Google API hizmetlerine kolayca erişmek ve istemci oluşturmak için kullanılır. `Googleapiclient.discovery` modülünün en önemli fonksiyonlarından biri `build()` fonksiyonudur. Bu fonksiyon, belirli bir Google API hizmetinin istemcisini oluşturmanıza olanak sağlar. İstemci, belirli bir API hizmetinin tüm işlevlerine erişim sağlar. Instagram, TikTok, Youtube gibi sosyal medya platformları 1 milyardan fazla aktif kullanıcıya sahip, günümüzde en popüler sosyal medya platformlarıdır. `Requests` kütüphanesi, Python programlama dilinde HTTP istekleri yapmak için bir araçtır. `Requests` kütüphanesinin temel işlevi, bir web sunucusuna HTTP isteği göndermek ve sunucudan gelen yanıtı almaktır. Bu işlev, `get()`, `post()`, `put()`, `delete()`, `patch()` gibi çeşitli yöntemlerle gerçekleştirilebilir. Her yöntem, farklı bir HTTP istek türüne karşılık gelir.

TikTok Developer, Youtube Developer ise bu platformların sunduğu araçlar ve API'ler aracılığıyla, geliştiricilerin sosyal medyanın gücünü kendi uygulamalarına ve web sitelerine entegre etmelerini sağlar. Streamlit, Python'da web uygulamaları oluşturmak için bir kütüphanedir. Makine öğrenmesi modellerini web üzerinde kullanıcılara sunmak için kullanılabilir.

3.3 Kullanılan Materyaller

Kaggle, veri bilimcileri ve makine öğrenmesi uzmanlarının kullandığı platformlardan biridir. Farklı veri setleri üzerinde çalışma fırsatı sunar. Google Colab, yapay zeka ve derin öğrenme projeleri için ücretsiz bir platformdur. Yapay zeka ve derin öğrenme projeleri üzerinde çalışanlar için paylaşımlı, bulut tabanlı, kullanımı kolay ve ortak çalışmaya dayalı bir programlama ortamıdır. (Google Colab,2022) PyCharm, Python programlama dili için güçlü bir IDE'dir. Kod yazma, hata ayıklama, test etme ve analiz etme gibi birçok özelliğe sahiptir. (Pycharm,2023) Python, genel amaçlı bir programlama dilidir. Veri bilimi ve makine öğrenmesi alanlarında yaygın olarak kullanılır. (Python,2024)

4. ARAŞTIRMA SONUÇLARI VE TARTIŞMA

Bu bölüm metin verilerini sınıflandırmak için bir makine öğrenimi modeli oluşturma ve analiz etme işlemini anlatmaktadır. Sosyal medyadan gelen yorumlar analiz edilip sınıflandırarak kullanıcıya sunulma ve sonuçları raporlama işlemi yapılmaktadır.

4.1 Modelin Eğitilmesi

Çalışmaya ilk olarak modelin eğitilmesi ile başlanmıştır. Ayrıca projenin en önemli adımıdır. Gerekli olan kütüphaneler import edilerek projeye başlanır. Projede kullanılan veri seti Kaggle üzerinden alınmıştır. İki farklı veri seti birleştirilerek yeni bir veri seti oluşturulmuştur. Veri seti Türkçe ve İngilizce nefret içerikli yorumlardan oluşmaktadır. Sekiz kolondan oluşan veri seti nefret içerikli yorumlar ve türleri hakkında bilgi verir (Şekil 1).

	id	comment_text	toxic	severe_toxic	obscene	threat	insult	identity_hate	char_length
0	0000997932d777bf	explanation why the edits made under my userna...	0	0	0	0	0	0	264
1	000103f0d9cfb60f	d aww he matches this background colour i am s...	0	0	0	0	0	0	112
2	000113f07ec002fd	hey man i am really not trying to edit war it ...	0	0	0	0	0	0	233
3	0001b41b1c6bb37e	more i cannot make any real suggestions on imp...	0	0	0	0	0	0	622
4	0001d958c54c6e35	you sir are my hero any chance you remember wh...	0	0	0	0	0	0	67
5	00025465d4725e87	congratulations from me as well use the tools ...	0	0	0	0	0	0	65
6	0002bcb3da6cb337	cocksucker before you piss around on my work	1	1	1	0	1	0	44
7	00031b1e95af7921	your vandalism to the matt shirvington article...	0	0	0	0	0	0	115
8	00037261f536c51d	sorry if the word nonsense was offensive to yo...	0	0	0	0	0	0	472
9	00040093b2687caa	alignment on this subject and which are contra...	0	0	0	0	0	0	70


Şekil 1. Kaggle'dan alınan veri seti

Projede daha iyi bir başarı sağlanması için veri analiz edilmiştir. Türkçe ve İngilizce yorumlar makine öğrenmesi modelinin anlaması için TfidfVectorizer ile sayısallaştırma işlemi yapılmıştır. Sayısallaştırılan veri seti test ve train olarak ayrılmıştır. Veri seti %80 eğitim ve %20 test kümeleri olmak üzere ayrılır. Bu çalışmada metin sınıflandırma için LightGBM tabanlı bir model oluşturulmuştur. Model birden fazla sınıfla eğitileceği için bu tür problemlerde kullanılan MultiOutputClassifier sınıfı ile geliştirilmiştir. Metin sayısallaştırıcı ve eğitilen model pickle kütüphanesiyle kaydedilir.

4.2 Sosyal Medyadan Yorum Çekilmesi ve Arayüz Tasarımı

Arayüz tasarımına kullanıcının incelemek istediği gönderinin url linki Streamlit kütüphanesi ile alınarak başlanır. Kullanıcı incelemek istediği gönderiyi girdiğinde giriş yapması veya kayıt olması gerektiği uyarısı karşısına çıkarır. Kullanıcının tercihinine göre kullanıcı girişi veya kayıt sayfasına yönlendirilir. (Şekil 2Error! Reference source not found.).

Giriş Yap



Şekil 2.Streamlit ile oluşturulan giriş sayfası

Kullanıcı kaydı oluşturulduktan sonra kullanıcı şifresi ve adı kontrolü yapılarak ana sayfaya yönlendirilir. Ardından kullanıcıdan incelemek istediği gönderi Url veya yorum metni alınır. Kullanıcı girişi olarak yorum girilirse yorum analiz edilir ve ardından olumsuz yorum ise türü belirlenir. (Şekil 3).



Şekil 3. Streamlit ile oluşturulan kullanıcı ana sayfası

Ardından bu çalışmada, YouTube ve TikTok videolarından yorumlar toplamak için iki fonksiyon geliştirilmiştir. `googleapiclient.discovery` kütüphanesi Youtube API'si ile iletişim kurmak için kullanılır. `Requests` kütüphanesi Web'den veri çekmek için kullanılır. `Requests` kütüphanesi Web'den veri çekmek için kullanılır. `get_video_id_from_url(url)` bir fonksiyon oluşturulur. `Urlparse` kütüphanesi kullanılarak kullanıcıdan Streamlit kütüphanesi aracılığı ile url alınır ve video ID'sini ayıklar ve ardından `youtube.commentThreads().list()` metoduna gönderilen video id sayesinde videoların altına gelen yorumlar çekilir. Çekilen yorumlar ve elde ettiğimiz bilgiler bir `DataFrame` tablosuna aktarılır ve Streamlit kütüphanesi yardımıyla kullanıcıya gösterilir. Alınan yorumlar bir döngü yardımıyla oluşturulan modele tahmin için aktarılır. Çıkan sonuç oluşturulan tabloya yeni bir kolon eklenerek kullanıcıya gösterilir. Sonuç kullanıcıya “Olumsuz İçerikli” ve “Olumsuz İçerikli Değil” şeklinde karşısına gelir. Diğer oluşturulan fonksiyon ise Tiktok yorumlarını çekmemize yardımcı olur. Kullanıcıdan alına url `requests` kütüphaneleri kullanılarak video adresi alınır. Headers değişkeni kullanarak TikTok API'sine istek gönderilirken kullanılacak http başlıklarını tanımlanır. Bu tanımlanan başlıklar web tarayıcı gibi davranarak TikTok'u yanıltmayı amaçlar. Yorumları almak için `requests.get()` fonksiyonu kullanılır. Tanımlana headers bilgileri de istek ile birlikte gönderilir. Alınan yorumlar bir döngüyle oluşturulan tabloya aktarılır. Ardından gelen yorumlar oluşturulan modele aktarılarak sonuç ekrana verilir. Kullanıcı “İncele” adlı butona bastığında Streamlit kütüphanesinin bir fonksiyonu olan `switch_page` kullanılarak raporlama sayfasına yönlendirilir. Raporlama sayfasında kullanıcı için oluşturulan tablolar, grafikler bulur. İlk tablo yorumlar ve yorumlara ait bilgiler içerir. Oluşturduğumuz fonksiyon ile birlikte alınan yorum sayısallaştırılır ardından modeldeki tahmine göre tabloda “Sonuç” adlı bir kolon oluşturulur (**Error! Reference source not found.**).

Tablo 1: Olumsuz Yorum İncelenmesi

	Yorum	Yorum Sahibi	Yayınlanma Tarihi	Sonuç
0	Müthiş! O zaman bildiriminizi dikkate almayacağım. Teşekkürler!	koalaolmakistiyom	2024-04-10T21:20:25.000	Olumsuz Değil
1	Beatifulll ☐	mxiass	2024-04-07T10:53:36.000	Olumsuz Değil
2	bayıldım	xyxyxyxy0206	2024-04-07T14:58:50.000	Olumsuz Değil
3	Amazingg 🍷	mxiass	2024-04-07T10:53:43.000	Olumsuz Değil
4	harika	xyxyxyxy0206	2024-04-07T14:58:47.000	Olumsuz Değil
5	Süper	mxiass	2024-04-07T14:03:25.000	Olumsuz Değil
6	Tony Sidaway is obviously a fistfuckee. He loves an arm up his ass	xyxyxyxy0206	2024-04-07T02:51:30.000	Olumsuz
7	GET FUCKED UP. GET FUCKEED UP. GOT A DRINK THAT YOU CANT PUT DOWN??/? GET FUCK UP GET FUCKED	xyxyxyxy0206	2024-04-07T02:51:16.000	Olumsuz
8	That's some cold ass shit, bruh	koalaolmakistiyom	2024-04-10T21:17:13.000	Olumsuz
9	You are gay or antisemmitian? Archangel WHite Tiger Meow! Greetingshhh! Uh, there are two ways	xyxyxyxy0206	2024-04-07T02:50:55.000	Olumsuz

Nefret içerikli olduğu tespit edilen yorumlar nefret türüne göre de analiz edilmek istenmiştir. Yorumlar kullanılan çoklu sınıflandırma modelinin verdiği sonuca göre bir DataFrame aktarılır (Tablo 2).


Tablo 2.Nefret içerikli yorumların türünün tespit edilmesi

	Yorum	Olumsuz	Nefret Söylemi	Müstehcen	Tehtit	Hakaret	Kimlik Nefreti
0	Tony Sidaway is obviously a fistfuckee. He loves an arm up his ass	Evet	Hayır	Evet	Hayır	Hayır	Hayır
1	GET FUCKED UP. GET FUCKEED UP. GOT A	Evet	Hayır	Evet	Hayır	Evet	Hayır

DRINK THAT YOU CANT PUT DOWN??/ GET FUCK UP GET FUCKED							
2	That's some cold ass shit, bruh	Evet	Hayır	Evet	Hayır	Hayır	Hayır
3	You are gay or antidemmitian? Archangel WHite Tiger Meow! Greetingshhh! Uh, there are two ways	Evet	Hayır	Hayır	Hayır	Hayır	Evet

DataFrame aktarılan veri plotly kütüphanesi kullanılarak görselleştirilmiştir. Nefret içerik türlerinin sayısı value_counts() fonksiyonu ile alınarak değişkenlere atanır. Bar grafik kullanılarak x eksenine nefret türleri, y eksenine nefret türlerinin sayısı atanarak görselleştirme işlemi yapılır. Bu görselleştirme işlemi, farklı nefret içerik türlerinin ne kadar sıklıkla geçtiğini net bir şekilde gösterir ve bu şekilde hangi türlerin daha yaygın olduğunu anlamamızı sağlar (Şekil 4).

Olumsuz Yorum Türü




Şekil 4. Nefret içerik türleri ve sayısı

DataFrame “Sonuç” kolonundaki toxic yorumlar ve toxic olmayan yorumlar value_counts() hesaplanır. Ardından subheader() ile yorumların nefret içerik oranı görselleştirilir. Nefret içerikli yorum yapan kullanıcıların tespit edilmesi için bar grafiği kullanılmıştır. Grafikte kullanıcı adı ve yapılan nefret içerikli yorum sayısını gösterir. Kullanıcı adı ve nefret içerikli yorum sayısı arasındaki ilişkiyi gösteren bar grafikleri,


topluluk normlarının ihlal edildiği durumları tespit etmeye yardımcı olabilir. Nefret içerikli yorumları tespit etmek ve kullanıcıların bu davranışlarını ele almak, çevrimiçi ortamları daha güvenli hale getirmek için önemlidir (Şekil 5).

Olumsuz Yorum Yapan Kullanıcılar



Şekil 5. Olumsuz yorum yapan kullanıcılar

Ardından hangi tarihlerde kaç tane kötü yorum yapılmış hangi tarihlerde kaç tane iyi yorum yapılmış olduğunu çizgi grafiği ile gösterilir. Verilerin tarih boyunca nasıl değiştiğini takip etmek için çizgi grafiklerinden faydalanabiliriz (Şekil 6).



Şekil 6. Tarihe göre olumsuz yorum sayısı

Kullanıcının sayfayı daha rahat uygulamayı daha rahat kullanılabilmesi için her sayfaya `st_navbar` fonksiyonuyla navbar eklenir. “Kullanıcı Bilgileri” kısmına basıldığında kullanıcı şifre ve kullanıcı adı değiştirme paneline yönlendirilir. (Şekil 7)

Şekil 7. Kullanıcı yardım paneli

“Yardım Paneli” ekranına tıkladığımızda bizi çok sorulan sorular ve cevapları şeklinde bir alan karşılar. Bu sayfa kullanıcının uygulamayı kullanırken karşılaşılabileceği sorunlara yönelik yardım paneli görevi üstlenir. (Şekil 8)

Şekil 8. Yardım paneli

Kullanıcı sayfa yöneticileriyle iletişim ve isteklerini iletebilmesi için “İletişim” kısmına tıkladığında bir form sayfası karşısına çıkar. Girilen bilgiler veritabanına aktarılır. (Şekil 9)

The screenshot shows a web interface with a dark blue navigation bar at the top containing the following links: 'Anasayfa', 'Kullanıcı Bilgileri', 'Yardım Paneli', 'İletişim' (which is highlighted in orange), and 'Çıkış Yap'. Below the navigation bar is a light blue header area with the title 'Bize Ulaşın' in bold black text. The main content area is white and contains a contact form. The form consists of three text input fields with labels 'İsminiz:', 'E-posta adresiniz:', and 'Mesajınız:' to their left. Below these fields is a dark blue button with the text 'Gönder' in white.

Şekil 9. İletişim paneli

Kullanıcı “Çıkış Yap” tıkladığına ise tekrardan kullanıcı giriş sayfasına yönlendirilir. Ardından kullanıcı veritabanında tutulan admin kolonundaki bilgiye göre bir kullanıcıya admin görevi verilir. Eğer kullanıcı giril yapılırken admin bilgisi “True” ise admin sayfasına yönlendirilir. “False” ise kullanıcı anasayfasına yönlendirilir. Ardından veritabanında olan bilgiler admin sayfasında görselleştirilir. Ve kullanıcı silme ve kullanıcı admin yap yetkileri de admin sayfasında sql sorgularıyla yapılır.

5. SONUÇLAR VE ÖNERİLER

Bu bölümde uygulamanın neticesinde elde edilen sonuçlar ve bu sonuçlar çerçevesinde ortaya çıkan öneriler anlatılmaktadır.

5.1 Sonuçlar

Bu çalışma, sosyal medyada nefret içerikli yorumların tespiti konusunda önemli bulgular ortaya koymaktadır. İnsanların çevrimiçi platformlarda ifade özgürlüğünü kullanırken sıklıkla nefret dolu mesajlar gönderdikleri ve bu durumun diğer kullanıcıları olumsuz etkilediği görülmektedir. Yapay zeka modelleri, sosyal medyadaki nefret içerikli yorumları analiz etmede oldukça faydalı bir araç olabilir. Bu modeller, büyük miktarda metni hızlı ve verimli bir şekilde işleyebilir ve nefret içeren dili tespit etmek için karmaşık algoritmalar kullanabilir. Bu tez çalışmasında, yapay zeka modellerinin sosyal medyadaki nefret içerikli yorumları analiz etmede ne kadar etkili olduğunu inceledik. Sonuçlarımız, yapay zeka modellerinin bu görevi yüksek bir doğrulukla gerçekleştirebildiğini gösterdi.

5.2 Öneriler

Bu tez çalışmasından elde edilen bulgular ışığında, yapay zeka modellerinin sosyal medyadaki nefret içerikli yorumlarla mücadelede önemli bir rol oynayabileceğini öneriyoruz. Gelecekteki araştırmalar, yapay zeka modellerinin bu görevi daha da etkili bir şekilde gerçekleştirmesine yardımcı olacak yeni algoritmaların geliştirilmesine odaklanmalıdır. Ayrıca, yapay zeka modellerinin etik kullanımı konusundaki endişelerin de ele alınması önemlidir.

6. KAYNAKLAR

- Aksakallı, G. (2023), Sosyal Medyada Nefret Söylemi: Toplumsal Sorunun Büyüyen Tehlikesi, Güvenli Web. <https://www.guvenliweb.org.tr/blog-detay> .[Ziyaret Tarihi: 9 Kasım 2023]
- Aljarah I, Habib M (2020) Intelligent detection of hate speech in Arabic social network: a machine learning approach.
- Al-Makhadmeh, Z., Tolba, A. (2019), Automatic hate speech detection using killer natural language processing optimizing ensemble deep learning approach
- Aşantıoğlu, N. & Karabacak Çelik, A. (2023), Lise Öğrencilerinde Sosyal Medya Bağımlılığı ile Sanal Zorba ve Mağdur Olma Arasındaki İlişkinin İncelenmesi. Online Journal of Technology Addiction and Cyberbullying, 10 (1), 1-16
- Birleşmiş Milletler (2022),<https://turkiye.un.org/tr>[Ziyaret Tarihi:9 Kasım 2023]
- Bisht A, Singh A, Bhadauria H, Virmani J and Kriti (2020), Detection of Hate Speech and Offensive Language in Twitter Data Using LSTM Model. Recent Trends in Image and Signal Processing in Computer Vision. 10.1007/978-981-15-2740-1_17. (243-264).
- Burnap P, Williams ML (2014) Hate speech, machine classification and statistical modelling of information flows on Twitter: interpretation and communication for policy decision making, pp 1–18
- Çelik, Deniz, Sosyal Medya’da Nefret Söylemine Bakış <https://www.umut.org.tr> [Ziyaret Tarihi: 30 Kasım 2023]
- Davidson T, Warmesley D, Macy M, Weber I (2013) Automated hate speech detection and the problem of offensive language
- Doğan B., Nefret ve Ayrımcılık Suçu, <https://barandogan.av.tr/blog> [Ziyaret Tarihi:9 Kasım 2023]
- Florio K, Basile V, Lai M, Patti V, Informatica D (2019) Leveraging hate speech detection to investigate immigration-related phenomena in Italy
- Ganesh R and T D. (2021), Prediction based on social media dataset using CNN-LSTM to classify the accurate Aggression level 2021 International Conference on Computer Communication and Informatics
- Google Colab(2022), Google Colab Nedir ve Nasıl Kullanılır?, <https://globalaihub.com/google-colab-nedir-ve-nasil-kullanilir/> [Ziyaret Tarihi:4 Ocak 2024]
- Greevy E, Smeaton AF (2004) Classifying racist texts using a support vector machine, pp 468–469

- Herodotou H, Chatzakou D and Kourtellis N.(2021), Catching them red-handed: Real-time Aggression Detection on Social Media 2021 IEEE 37th International Conference on Data Engineering (ICDE).
- Islam MM, Uddin MA, Islam L, Akter A, Sharmin S, Acharjee UK (2020) Cyberbullying detection on social networks using machine learning approaches. 2020 IEEE Asia-Pacific Conf Comput Sci Data Eng CSDE 2020.
- K. Yousaf and T. Nawaz, (2022), A Deep Learning-Based Approach for Inappropriate Content Detection and Classification of YouTube Videos, in IEEE Access, vol. 10, pp. 16283-16298, 2022, doi: 10.1109/ACCESS.2022.3147519.
- Kolhatkar V, Wu H, Cavasso L, Francis E, Shukla K and Taboada M. (2019), The SFU Opinion and Comments Corpus: A Corpus for the Analysis of Online News Comments. Corpus Pragmatics. 10.1007/s41701-019-00065-w.
- Kwok, I., and Wang, Y. (2013), Locate the Hate: Detecting Tweets against Blacks. Proceedings of the Twenty-Seventh AAAI Conference on Artificial Intelligence, (s. 1621-1622).
- Mahajan E, Mahajan H and Kumar S. (2024), EnsMulHateCyb: Multilingual hate speech and cyberbully detection in online social media. Expert Systems with Applications. 10.1016/j.eswa.2023.121228. 236. (121228). Online publication date: 1-Feb-2024.
- Özbay E. (2022), Transformatör-Tabanlı Evrişimli Sinir Ağı Modeli Kullanarak Twitter Verisinde Saldırganlık Tespiti Aggression Detection İn Twitter Data Using Transformer-Based Convolutional Neural Network Model. Konya Journal Of Engineering Sciences. 10.36306/Konjes.1061807. 10:4. (986-1001).
- Padmaja PS, Bandu S (2014) Evaluating sentiment analysis methods and identifying scope of negation in newspaper articles. Int J Adv Res Artif Intell 3(11):1–6.
- Pandas(2023),Pandas Kütüphanesi Hakkında Detaylı İnceleme ve Kod Örnekleri, https://www.codingtxt.com/blog/detail/pandas-kutuphanesi-hakkinda-detayli-inceleme-ve-kod-ornekleri-79748d49-9156-45#google_vignette&gsc.tab=0 [Ziyaret Tarihi:4 Ocak 2024]
- Perifanos K, Goutsos D (2021) Multimodal hate speech detection in Greek social media. Multimodal Technol Interact 5(7).
- Priya and Gupta S. (2023), Identification of Political Hate Speech Using Machine Learning-Based Text Toxicity Analysis. ICT Systems and Sustainability.
- Pycharm(2023),Pycharm Nedir? Ne İşe Yarar?, <https://aws.amazon.com/tr/what-is/python/> [Ziyaret Tarihi:4 Ocak 2024]
- Python(-),Python Nedir?,<https://aws.amazon.com/tr/what-is/python/>[Ziyaret Tarihi:4 Ocak 2024]

- Raisi E, Huang B (2017) Cyberbullying detection with weakly supervised machine learning. In: Proceedings 2017 IEEE/ACM international conference advanced social networks anal mining, ASONAM 2017, pp 409–416.
- Tfid(2021), TF IDF Nedir?, <https://www.turhost.com/blog/tf-idf-nedir/> [Ziyaret Tarihi:27 Aralık 2023]
- Tomkins S, Getoor L, Chen Y, Zhang Y (2018) A socio-linguistic model for cyberbullying detection. Proc 2018 IEEE/ACM Int Conf Adv Soc Networks Anal Mining, ASONAM 2018, pp 53–60.
- Tutgun-Ünal, Aylin ve Levent Deniz (2020), Sosyal Medya Kuşaklarının Sosyal Medya Kullanım Seviyeleri ve Tercihleri, Opus Uluslararası Toplum Araştırmaları Dergisi, Cilt 15, Sayı 22.
- Yapay Zeka(-),Yapay Zeka Nedir?, <https://www.trendmicro.comlearning> [Ziyaret Tarihi:4 Ocak 2024]

ÖZGEÇMİŞ**KİŞİSEL BİLGİLER**

Adı Soyadı : Hilal Akçakaya
Uyruğu : Türk
Doğum Yeri ve Tarihi : Bolu-13.05.2002
Telefon : 05468727780
e-mail : hilal_akcakaya14@hotmail.com

EĞİTİM

Derece	Adı, İlçe, İl	Bitirme Yılı
Lise	: Altındağ Mehmet Akif Ersoy Anadolu Lisesi, Altındağ, Ankara	2020
Üniversite	: Necmettin Erbakan Üniversitesi, Seydişehir, Konya	2024

İŞ DENEYİMLERİ

Yıl	Kurum	Görevi
2022	İşkur Bilgi İşlem Daire Başkanlığı	Stajyer
2023	Orman Genel Müdürlüğü Bilgi İşlem Daire Başkanlığı	Stajyer
2024	Çevre, İklim ve Şehircilik Bakanlığı	İntern

UZMANLIK ALANI

YABANCI DİLLER: İngilizce